

Pracownia Problemowa 1

Maciej Sikora
Patryk Krukowski

1 Ogólny wstęp

1.1 Pochodne funkcji straty

Odpowiednie pochodne funkcji straty zostały policzone symbolicznie w kodzie Matlab, który zamieścimy w niniejszej sekcji w dalszym ciągu raportu.

2 Pierwsza zmodyfikowana sieć neuronowa

W metodzie tej będziemy przybliżać w sposób bezpośredni kombinację liniową B-spline'ów

$$y(x) = u_1 B_{1,2}(x) + u_2 B_{2,2}(x) + u_3 B_{3,2}(x)$$

ze współczynnikami rzeczywistymi u_1 , u_2 oraz u_3 , biorąc jako funkcję aproksymującą naszą zmodyfikowaną sieć, tzn.

$$ANN(x) = c_1 \sigma(c_2 \sigma(\dots c_k \sigma(a_{k1} + a_{k2}x + b_k) + d_k) \dots + d_2) + d_1.$$

Modyfikacja polega na tym, że uwzględniamy w sieci k warstw. Poniższe wyniki przedstawimy dla $k = 3$.

2.1 Funkcja straty

Funkcję straty definiujemy następująco:

$$error_1(x, a, b, c, d) = 0.5 * (ANN(x) - (u_1 * B_{1,2}))^2$$

$$error_2(x, a, b, c, d) = 0.5 * (ANN(x) - (u_2 * B_{2,2}))^2$$

$$error_3(x, a, b, c, d) = 0.5 * (ANN(x) - (u_3 * B_{3,2}))^2$$

2.2 Pseudokod procesu uczenia

1. Dane wejściowe - liczba warstw.
2. Generujemy dataset składający się z generacji $x \in (0, 0.5)$ oraz $n = 0.44$.
3. Korzystając ze znanego rozwiązania problemu IGA, generujemy współczynniki u_1, u_2, u_3 .
4. Dla każdej warstwy sieci:
 - (a) Liczymy $ANN(x)$.
 - (b) Liczymy $e_1(x), e_2(x), e_3(x)$.
 - (c) Liczymy pochodne cząstkowe pierwszego rzędu z $e(x)$ po każdym parametrze.
 - (d) Uczymy parametry stochastycznym spadkiem wzdłuż gradientu, biorąc stałą uczącą $\eta \in (0, 1)$.

2.3 Kod Matlaba

```

1 function ANN_1(layers_number)
2 %
3 %%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%
4
5 %Preparation of dataset
6
7 %collection of dataset
8 A = [1/5 1/10 1/30; 1/10 2/15 1/10; 1/30 1/10 1/5];
9 i=1;
10 for n=0.01:0.01:0.5
11     rhs= [ (pi*pi*n*n+2*cos(pi*n)-2)/(pi*pi*pi*n*n*n);
12           (-2*pi*n*sin(pi*n)-4*cos(pi*n)+4)/(pi*pi*pi*n*n*n);

```

```

11 ((2-pi*pi*n*n)*cos(pi*n)+2*pi*n*sin(pi*n)-2)/(pi*pi*pi
    *n*n*n) ];
12 A;
13 rhs;
14 u=A\rhs;
15 dataset_in(i)=n;
16 dataset_u1(i)=u(1);
17 dataset_u2(i)=u(2);
18 dataset_u3(i)=u(3);
19 i=i+1;
20 end
21 ndataset=i-1;
22
23 %
    %%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%
24 %training
25
26 vec_a1=ones(1, layers_number);
27 vec_b1=ones(1, layers_number);
28 vec_c1=ones(1, layers_number);
29 vec_d1=zeros(1, layers_number);
30
31 vec_a2=ones(1, layers_number);
32 vec_b2=ones(1, layers_number);
33 vec_c2=ones(1, layers_number);
34 vec_d2=zeros(1, layers_number);
35
36 vec_a3=ones(1, layers_number);
37 vec_b3=ones(1, layers_number);
38 vec_c3=ones(1, layers_number);
39 vec_d3=zeros(1, layers_number);
40

```

```

41  smallest_err_u1=1000;
42  smallest_err_u2=1000;
43  smallest_err_u3=1000;
44
45
46  biggest_err_u1=0;
47  biggest_err_u2=0;
48  biggest_err_u3=0;
49
50  eta1=0.1;
51  eta2=0.1;
52  eta3=0.1;
53  r = 0 + (1-0).*rand(ndataset,1);
54  r=r.*ndataset;
55  n=0.444;
56  for idx=1:layers_number
57      %Symbolic functions
58
59      %Symbolic sigmoid
60      syms z a1 b1
61      a=sym('a', [1, idx]);
62      b=sym('b', [1, idx]);
63      c=sym('c', [1, idx]);
64      d=sym('d', [1, idx]);
65
66      sigmoid(z,a1,b1) = a1/(1+exp(-z))+b1;
67
68      result=sigmoid(z*a(idx)+b(idx), c(idx), d(idx));
69      if(idx>1)
70          for l=1:idx-1
71              result=sigmoid(a(idx-1)*result+b(idx-1), c
              (idx-1), d(idx-1));
72          end

```

```

73     end
74     ann_3(z,a,b,c,d)=result;
75
76
77     %Symbolic first and second derivative of PINN with
       respect to x
78
79     %Symbolic PDE solver function
80     temp=[a, b, c, d];
81     combined=temp(:);
82     combined=num2cell(combined);
83
84     %Symbolic error1 function
85     error1(z, a, b, c, d)=0.5 * ( ...
86         ann_3(z,combined{:}) ...
87         - ( ...
88             ((pi*pi*n*n+2*cos(pi*n)-2)/(pi*pi*pi*n*n*n)) *
              (1-z)^2 ...
89             ) ...
90         )^2;
91
92     error2(z, a, b, c, d)=0.5 * ( ...
93         ann_3(z,combined{:}) ...
94         - ( ...
95             ((-2*pi*n*sin(pi*n)-4*cos(pi*n)+4)/(pi*pi*pi*n
              *n*n)) * 2*z*(1-z) ...
96             ) ...
97         )^2;
98
99     error3(z, a, b, c, d)=0.5 * ( ...
100         ann_3(z,combined{:}) ...
101         - ( ...
102             (((2-pi*pi*n*n)*cos(pi*n)+2*pi*n*sin(pi*n)-2)

```

```

        /((pi*pi*pi*n*n*n)) * z^2 ...
103     ) ...
104     )^2;
105
106
107     for j=1:ndataset
108         params_u1(1:idx)=vec_a1(1:idx);
109         params_u1(idx+1:2*idx)=vec_b1(1:idx);
110         params_u1(2*idx+1:3*idx)=vec_c1(1:idx);
111         params_u1(3*idx+1:4*idx)=vec_d1(1:idx);
112
113         params_u2(1:idx)=vec_a2(1:idx);
114         params_u2(idx+1:2*idx)=vec_b2(1:idx);
115         params_u2(2*idx+1:3*idx)=vec_c2(1:idx);
116         params_u2(3*idx+1:4*idx)=vec_d2(1:idx);
117
118         params_u3(1:idx)=vec_a3(1:idx);
119         params_u3(idx+1:2*idx)=vec_b3(1:idx);
120         params_u3(2*idx+1:3*idx)=vec_c3(1:idx);
121         params_u3(3*idx+1:4*idx)=vec_d3(1:idx);
122
123         params_u1_combined=num2cell(params_u1);
124         params_u2_combined=num2cell(params_u2);
125         params_u3_combined=num2cell(params_u3);
126         i=floor(r(j));
127         if(i==0)
128             i=1;
129         end
130         %%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%
131         %Approximation of u1, u2 and u3 coefficients
132         eval_u1 = double(ann_3(dataset_in(i),
133             params_u1_combined{:}));
134         eval_u2 = double(ann_3(dataset_in(i),

```

```

        params_u2_combined{:}));
134 eval_u3 = double(ann_3(dataset_in(i),
        params_u3_combined{:}));
135
136 %Errors
137 error_u1 = 0.5*(eval_u1-dataset_u1(i))^2;
138 error_u2 = 0.5*(eval_u2-dataset_u2(i))^2;
139 error_u3 = 0.5*(eval_u3-dataset_u3(i))^2;
140 %Symbolic differentiation
141 d_error_1_a(z, a, b, c, d)=diff(error1, a(idx));
142 d_error_1_b(z, a, b, c, d)=diff(error1, b(idx));
143 d_error_1_c(z, a, b, c, d)=diff(error1, c(idx));
144 d_error_1_d(z, a, b, c, d)=diff(error1, d(idx));
145
146 derror_u1_1a=double(d_error_1_a(dataset_in(i),
        params_u1_combined{:}));
147 derror_u1_1b=double(d_error_1_b(dataset_in(i),
        params_u1_combined{:}));
148 derror_u1_1c=double(d_error_1_c(dataset_in(i),
        params_u1_combined{:}));
149 derror_u1_1d=double(d_error_1_d(dataset_in(i),
        params_u1_combined{:}));
150
151 derror_u2_1a=double(d_error_1_a(dataset_in(i),
        params_u2_combined{:}));
152 derror_u2_1b=double(d_error_1_b(dataset_in(i),
        params_u2_combined{:}));
153 derror_u2_1c=double(d_error_1_c(dataset_in(i),
        params_u2_combined{:}));
154 derror_u2_1d=double(d_error_1_d(dataset_in(i),
        params_u2_combined{:}));
155
156 derror_u3_1a=double(d_error_1_a(dataset_in(i),

```

```

        params_u3_combined{:}));
157 derror_u3_1b=double(d_error_1_b(dataset_in(i),
        params_u3_combined{:}));
158 derror_u3_1c=double(d_error_1_c(dataset_in(i),
        params_u3_combined{:}));
159 derror_u3_1d=double(d_error_1_d(dataset_in(i),
        params_u3_combined{:}));
160
161 % Training of the boundary condition at x=0
162 d_error_2_a(z, a, b, c, d)=diff(error2, a(idx));
163 d_error_2_b(z, a, b, c, d)=diff(error2, b(idx));
164 d_error_2_c(z, a, b, c, d)=diff(error2, c(idx));
165 d_error_2_d(z, a, b, c, d)=diff(error2, d(idx));
166
167 derror_u1_2a=double(d_error_2_a(dataset_in(i),
        params_u1_combined{:}));
168 derror_u1_2b=double(d_error_2_b(dataset_in(i),
        params_u1_combined{:}));
169 derror_u1_2c=double(d_error_2_c(dataset_in(i),
        params_u1_combined{:}));
170 derror_u1_2d=double(d_error_2_d(dataset_in(i),
        params_u1_combined{:}));
171
172 derror_u2_2a=double(d_error_2_a(dataset_in(i),
        params_u2_combined{:}));
173 derror_u2_2b=double(d_error_2_b(dataset_in(i),
        params_u2_combined{:}));
174 derror_u2_2c=double(d_error_2_c(dataset_in(i),
        params_u2_combined{:}));
175 derror_u2_2d=double(d_error_2_d(dataset_in(i),
        params_u2_combined{:}));
176
177 derror_u3_2a=double(d_error_2_a(dataset_in(i),

```



```

        params_u3_combined{:}));
178 derror_u3_2b=double(d_error_2_b(dataset_in(i),
        params_u3_combined{:}));
179 derror_u3_2c=double(d_error_2_c(dataset_in(i),
        params_u3_combined{:}));
180 derror_u3_2d=double(d_error_2_d(dataset_in(i),
        params_u3_combined{:}));
181
182
183 % Training of the boundary condition at x=0.5
184 d_error_3_a(z, a ,b, c, d)=diff(error3, a(idx));
185 d_error_3_b(z, a, b, c, d)=diff(error3, b(idx));
186 d_error_3_c(z, a, b, c, d)=diff(error3, c(idx));
187 d_error_3_d(z, a, b, c, d)=diff(error3, d(idx));
188
189 derror_u1_3a=double(d_error_3_a(dataset_in(i),
        params_u1_combined{:}));
190 derror_u1_3b=double(d_error_3_b(dataset_in(i),
        params_u1_combined{:}));
191 derror_u1_3c=double(d_error_3_c(dataset_in(i),
        params_u1_combined{:}));
192 derror_u1_3d=double(d_error_3_d(dataset_in(i),
        params_u1_combined{:}));
193
194 derror_u2_3a=double(d_error_3_a(dataset_in(i),
        params_u2_combined{:}));
195 derror_u2_3b=double(d_error_3_b(dataset_in(i),
        params_u2_combined{:}));
196 derror_u2_3c=double(d_error_3_c(dataset_in(i),
        params_u2_combined{:}));
197 derror_u2_3d=double(d_error_3_d(dataset_in(i),
        params_u2_combined{:}));
198

```

```

199     derror_u3_3a=double(d_error_3_a(dataset_in(i),
200         params_u3_combined{:}));
201     derror_u3_3b=double(d_error_3_b(dataset_in(i),
202         params_u3_combined{:}));
203     derror_u3_3c=double(d_error_3_c(dataset_in(i),
204         params_u3_combined{:}));
205     derror_u3_3d=double(d_error_3_d(dataset_in(i),
206         params_u3_combined{:}));
207
208     vec_a1(idx)=vec_a1(idx) - eta1*(derror_u1_1a);
209     vec_b1(idx)=vec_b1(idx) - eta1*(derror_u1_1b);
210     vec_c1(idx)=vec_c1(idx) - eta1*(derror_u1_1c);
211     vec_d1(idx)=vec_d1(idx) - eta1*(derror_u1_1d);
212
213     vec_a2(idx)=vec_a2(idx) - eta2*(derror_u2_2a);
214     vec_b2(idx)=vec_b2(idx) - eta2*(derror_u2_2b);
215     vec_c2(idx)=vec_c2(idx) - eta2*(derror_u2_2c);
216     vec_d2(idx)=vec_d2(idx) - eta2*(derror_u2_2d);
217
218     vec_a3(idx)=vec_a3(idx) - eta3*(derror_u3_3a);
219     vec_b3(idx)=vec_b3(idx) - eta3*(derror_u3_3b);
220     vec_c3(idx)=vec_c3(idx) - eta3*(derror_u3_3c);
221     vec_d3(idx)=vec_d3(idx) - eta3*(derror_u3_3d);
222
223     if(error_u1 < smallest_err_u1)
224         smallest_err_u1=error_u1;
225         best_params_u1=num2cell(params_u1);
226         min_diff_u1=error_u1;
227     end
228
229     if(error_u1 > biggest_err_u1)
230         biggest_err_u1=error_u1;
231         max_diff_u1=error_u1;

```

```

228         end
229
230         if(error_u2 < smallest_err_u2)
231             smallest_err_u2=error_u2;
232             best_params_u2=num2cell(params_u2);
233             min_diff_u2=error_u2;
234         end
235
236         if(error_u2 > biggest_err_u2)
237             biggest_err_u2=error_u2;
238             max_diff_u2=error_u2;
239         end
240
241         if(error_u3 < smallest_err_u3)
242             smallest_err_u3=error_u3;
243             best_params_u3=num2cell(params_u3);
244             min_diff_u3=error_u3;
245         end
246
247         if(error_u3 > biggest_err_u3)
248             biggest_err_u3=error_u3;
249             max_diff_u3=error_u3;
250         end
251
252         yeval_u1(j+(idx*ndataset-ndataset))=eval_u1;
253         yeval_u2(j+(idx*ndataset-ndataset))=eval_u2;
254         yeval_u3(j+(idx*ndataset-ndataset))=eval_u3;
255
256         ya_u1(j+(idx*ndataset-ndataset))=vec_a1(idx);
257         yb_u1(j+(idx*ndataset-ndataset))=vec_b1(idx);
258         yc_u1(j+(idx*ndataset-ndataset))=vec_c1(idx);
259         yd_u1(j+(idx*ndataset-ndataset))=vec_d1(idx);
260

```

```

261     ya_u2(j+(idx*ndataset-ndataset))=vec_a2(idx);
262     yb_u2(j+(idx*ndataset-ndataset))=vec_b2(idx);
263     yc_u2(j+(idx*ndataset-ndataset))=vec_c2(idx);
264     yd_u2(j+(idx*ndataset-ndataset))=vec_d2(idx);
265
266     ya_u3(j+(idx*ndataset-ndataset))=vec_a3(idx);
267     yb_u3(j+(idx*ndataset-ndataset))=vec_b3(idx);
268     yc_u3(j+(idx*ndataset-ndataset))=vec_c3(idx);
269     yd_u3(j+(idx*ndataset-ndataset))=vec_d3(idx);
270
271
272     yy_u1(j+(idx*ndataset-ndataset))=dataset_u1(i);
273     yy_u2(j+(idx*ndataset-ndataset))=dataset_u2(i);
274     yy_u3(j+(idx*ndataset-ndataset))=dataset_u3(i);
275     ye_u1(j+(idx*ndataset-ndataset))=error_u1
276     ye_u2(j+(idx*ndataset-ndataset))=error_u2;
277     ye_u3(j+(idx*ndataset-ndataset))=error_u3;
278     j
279     end
280     idx
281     end
282     %
283     %%%%%%%%%%%
284
285     % plot convergence
286     % plot convergence
287     x=1:layers_number*ndataset;
288     % hold on
289     % Vectors parameters have parameters from every layer
290     on the same plot!
291     plot(x, ya_u1, x, yb_u1, x, yc_u1, x, yd_u1);
292     h=legend('a_{u1}', 'b_{u1}', 'c_{u1}', 'd_{u1}');
293     set(h, 'FontSize', 10);

```

```

291 figure
292
293 plot(x, ya_u2, x, yb_u2, x, yc_u2, x, yd_u2);
294 h=legend('a_{u2}', 'b_{u2}', 'c_{u2}', 'd_{u2}');
295 set(h, 'FontSize', 10);
296 figure
297
298 plot(x, ya_u3, x, yb_u3, x, yc_u3, x, yd_u3);
299 h=legend('a_{u3}', 'b_{u3}', 'c_{u3}', 'd_{u3}');
300 set(h, 'FontSize', 10);
301
302 figure
303
304 %
305 %%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%
306
307 % plot error
308
309 x=1:1:layers_number*ndataset;
310 % hold on
311
312
313
314 plot(x, ye_u1, x, ye_u2, x, ye_u3);
315 h=legend('error(u1)', 'error(u2)', 'error(u3)');
316 set(h, 'FontSize', 20);
317 set(gca, 'YScale', 'log');
318
319 %
320 %%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%
321
322 % Computing maximum and minimum difference for u(1), u
323 (2) and u(3)
324
325 max_diff_u1
326 min_diff_u1
327
328

```


```

319 max_diff_u2
320 min_diff_u2
321
322 max_diff_u3
323 min_diff_u3
324
325 %
    %%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%


326 best_params_u1
327 best_params_u2
328 best_params_u3
329
330 end

```


2.4 Zbieżność współczynników



Rysunek 1: Zbieżność uczonych parametrów u_1




Rysunek 2: Zbieżność uczonych parametrów u_2



Rysunek 3: Zbieżność uczonych parametrów u_3

2.5 Zbieżność błędu funkcji straty



Rysunek 4: Funkcje błędu e_1, e_2, e_3

2.6 Maksymalna, minimalna wartość błędu oraz najlepsze parametry

$$\max_diff_u1 = 0.3174$$

$$\max_diff_u2 = 0.2956$$

$$\max_diff_u3 = 0.4638$$

$$\min_diff_u1 = 8.4484e - 04$$

$$\min_diff_u2 = 3.3425e - 05$$

$$\min_diff_u3 = 6.1907e - 04$$

$$\text{best_params_u1} \Rightarrow 0.9809, 0.9369, 0.6577, -0.4380$$

$$\text{best_params_u2} \Rightarrow 0.9831, 0.9997, 0.9357, 0.9987, 0.6616, 0.9944, -0.4376, -0.0073$$

$$\text{best_params_u3} \Rightarrow 0.9816, 0.9994, 0.9325, 0.9966, 0.6384, 0.9855, -0.4666, -0.0189$$

3 Druga zmodyfikowana sieć neuronowa

W metodzie tej będziemy przybliżać w sposób bezpośredni kombinację liniową B-spline'ów

$$y(n, x) = u_1(n)B_{1,2}(x) + u_2(n)B_{2,2}(x) + u_3(n)B_{3,2}(x)$$

ze współczynnikami rzeczywistymi u_1 , u_2 oraz u_3 , biorąc jako funkcję aproksymującą naszą zmodyfikowaną sieć, tzn.

$$ANN(n, x) = c_1\sigma(c_2\sigma(\dots c_k\sigma(a_{k1}n + a_{k2}x + b_k) + d_k) \dots + d_2) + d_1.$$

Modyfikacja polega na tym, że uwzględniamy w sieci k warstw. Poniższe wyniki przedstawimy dla $k = 3$.

3.1 Funkcja straty

Funkcję straty definiujemy następująco:

$$e(n, x) = 0.5 \cdot (ANN(n, x) - y(n, x))^2.$$

3.2 Pochodne funkcji straty

Odpowiednie pochodne funkcji straty zostały policzone symbolicznie w kodzie Matlaba, który zamieścimy w niniejszej sekcji w dalszym ciągu raportu.

3.3 Pseudokod procesu uczenia

1. Dane wejściowe - liczba warstw.
2. Generujemy dataset składający się z generacji $n, x \in (0, 0.5)$.
3. Korzystając ze znanego rozwiązania problemu IGA, generujemy współczynniki u_1 , u_2 , u_3 , a następnie $y(n, x)$.
4. Dla każdej warstwy sieci:
 - (a) Liczymy $ANN(n, x)$.
 - (b) Liczymy $e(n, x)$.

- (c) Liczymy pochodne cząstkowe pierwszego rzędu z $e(n, x)$ po każdym parametrze.
- (d) Uczymy parametry stochastycznym spadkiem wzdłuż gradientu, biorąc stałą uczącą $\eta \in (0, 1)$.

Kod Matlaba

```

1 function ANN_2(layers_number)
2
3 %Preparation of dataset
4
5 %collection of dataset
6 A = [1/5 1/10 1/30; 1/10 2/15 1/10; 1/30 1/10 1/5];
7 i=1;
8 for n=0.1:0.1:0.5
9     for x=0.1:0.1:0.5
10        rhs= [ (pi*pi*n*n+2*cos(pi*n)-2)/(pi*pi*pi*n*n*n);
11              (-2*pi*n*sin(pi*n)-4*cos(pi*n)+4)/(pi*pi*pi*n*n*n)
12              ;
13              ((2-pi*pi*n*n)*cos(pi*n)+2*pi*n*sin(pi*n)-2)/(pi*
14                pi*pi*n*n*n) ];
15        u=A \ rhs;
16        y=u(1)*(1-x)^2+u(2)*2*x.*(1-x)+u(3)*x^2;
17        dataset_in_n(i)=n;
18        dataset_in_x(i)=x;
19        dataset_y(i)=y;
20        i=i+1;
21    end
22 end
23 ndataset=i-1;
24
25 r = 0 + (1-0).*rand(ndataset,1);
26 r=r.*ndataset;

```

```

25 % Training
26
27 vec_a1=ones(1, layers_number);
28 vec_a2=ones(1, layers_number);
29 vec_b=ones(1, layers_number);
30 vec_c=zeros(1, layers_number);
31 vec_d=zeros(1, layers_number);
32
33 eta=0.1;
34 smallest_error=1000;
35 biggest_error=0;
36 for idx=1:layers_number
37     %Symbolic functions
38
39     %Symbolic sigmoid
40     syms z n e f g h p
41     a1=sym('a1', [1, idx]);
42     a2=sym('a2', [1, idx]);
43     b=sym('b', [1, idx]);
44     c=sym('c', [1, idx]);
45     d=sym('d', [1, idx]);
46
47     sigmoid(z,n,e,f,g,h,p) = h/(1+exp(-z*e-n*f-g))+p;
48
49     result=sigmoid(z,n, a1(idx), a2(idx), b(idx), c(
        idx), d(idx));
50     if(idx>1)
51         for l=1:idx-1
52             result=sigmoid(result,n,a1(idx-1),a2(idx-1
                ),b(idx-1),c(idx-1),d(idx-1));
53         end
54     end
55     ann_2(z,n,a1,a2,b,c,d)=result;

```

```

56
57 y=(pi*pi*n*n+2*cos(pi*n)-2)/(pi*pi*pi*n*n*n)*(1-z)
      ^2 + (-2*pi*n*sin(pi*n)-4*cos(pi*n)+4)/(pi*pi*
      pi*n*n*n)*(1-z) + ((2-pi*pi*n*n)*cos(pi*n)+2*pi
      *n*sin(pi*n)-2)/(pi*pi*pi*n*n*n)*z^2;
58 y(z,n)=y;
59 %Symbolic MSE
60 temp=[a1, a2, b, c, d];
61 combined=temp(:);
62 combined=num2cell(combined);
63 err(z,n,a1,a2,b,c,d)=0.5*(ann_2(z,n,combined{:}) -
      y(z,n))^2;
64
65 for j=1:ndataset
66     i=floor(r(j));
67
68     if(i==0)
69         i=1;
70     end
71
72     params(1:idx)=vec_a1(1:idx);
73     params(idx+1:2*idx)=vec_a2(1:idx);
74     params(2*idx+1:3*idx)=vec_b(1:idx);
75     params(3*idx+1:4*idx)=vec_c(1:idx);
76     params(4*idx+1:5*idx)=vec_d(1:idx);
77
78     params_combined=num2cell(params);
79
80     %Approximation of y
81     eval = double(ann_2(dataset_in_x(i), dataset_in_n
      (i), params_combined{:}));
82     error = 0.5*(eval-dataset_y(i))^2;
83

```

```

84     if(error < smallest_error)
85         smallest_error=error;
86         best_params=num2cell(params);
87     end
88
89     if(error > biggest_error)
90         biggest_error=error;
91     end
92
93     %Symbolic differentiation
94     d_error_a1(z, n, a1, a2, b, c, d)=diff(err, a1(
95         idx));
96     d_error_a2(z,n,a1,a2, b, c, d)=diff(err, a2(idx))
97         ;
98     d_error_b(z,n,a1,a2, b, c, d)=diff(err, b(idx));
99     d_error_c(z,n,a1,a2, b, c, d)=diff(err, c(idx));
100     d_error_d(z,n,a1,a2, b, c, d)=diff(err, d(idx));
101
102     derror_a1=double(d_error_a1(dataset_in_x(i),
103         dataset_in_n(i), params_combined{:}));
104     derror_a2=double(d_error_a2(dataset_in_x(i),
105         dataset_in_n(i), params_combined{:}));
106     derror_b=double(d_error_b(dataset_in_x(i),
107         dataset_in_n(i), params_combined{:}));
108     derror_c=double(d_error_c(dataset_in_x(i),
109         dataset_in_n(i), params_combined{:}));
110     derror_d=double(d_error_d(dataset_in_x(i),
111         dataset_in_n(i), params_combined{:}));
112
113     vec_a1(idx)=vec_a1(idx) - eta*derror_a1;
114     vec_a2(idx)=vec_a2(idx) - eta*derror_a2;
115     vec_b(idx)=vec_b(idx) - eta*derror_b;
116     vec_c(idx)=vec_c(idx) - eta*derror_c;

```

```

110     vec_d(idx)=vec_d(idx) - eta*derror_d;
111
112     yeval(j+(idx*ndataset-ndataset))=eval;
113     yy(j+(idx*ndataset-ndataset))=dataset_y(i);
114     ya1(j+(idx*ndataset-ndataset))=vec_a1(idx);
115     ya2(j+(idx*ndataset-ndataset))=vec_a2(idx);
116     yb(j+(idx*ndataset-ndataset))=vec_b(idx);
117     yc(j+(idx*ndataset-ndataset))=vec_c(idx);
118     yd(j+(idx*ndataset-ndataset))=vec_d(idx);
119     ye(j+(idx*ndataset-ndataset))=error
120     j
121
122     end
123     idx
124 end
125
126 %
127 %%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%
128 % plot convergence
129 x=1:ndataset*layers_number;
130 plot(x, ya1, x, ya2, x, yb, x, yc, x, yd);
131 h=legend('a1', 'a2', 'b', 'c', 'd');
132 set(h, 'FontSize', 20);
133
134
135 figure
136
137 %
138 %%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%
139 % plot error

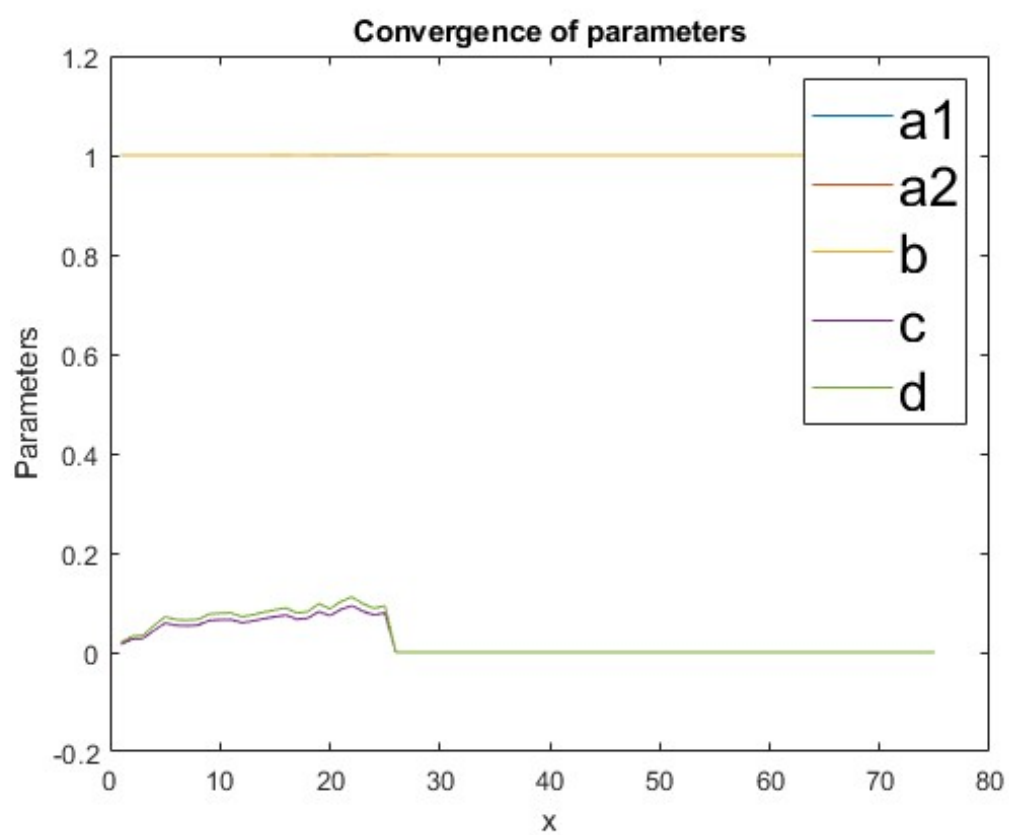
```

```

139 x=1:layers_number*ndataset;
140 % hold on
141
142 plot(x,ye);
143 h=legend('error');
144 set(h,'FontSize',20);
145 set(gca,'YScale','log');
146
147 %
    %%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%
148 % The biggest and the smallest error, and the best
    % parameters from all
149 % layers
150
151 biggest_error
152 smallest_error
153 best_params
154
155 end


```

3.4 Zbieżność współczynników



Rysunek 5: Zbieżność uczonych parametrów

3.5 Zbieżność błędu funkcji straty



Rysunek 6: Zbieżność błędu funkcji straty

3.6 Maksymalna, minimalna wartość błędu oraz najlepsze parametry

- Największy błąd: 0.1153
- Najmniejszy błąd: $3.7660e^{-6}$

4 Trzecia zmodyfikowana sieć neuronowa

W metodzie tej będziemy przybliżać współczynniki kombinacji liniowej u_1 , u_2 oraz u_3 poprzez użycie Physics Informed Neural Network. Poniższe wyniki przedstawimy dla trzech warstw.

4.1 Funkcja straty

Funkcję straty dla i -tego współczynnika u_i definiujemy następująco:

$$e_{1,i}(x) = 0.5 \cdot (PINN_{xx,i}(x) + n^2 \pi^2 \sin(n\pi x))^2.$$

Definiujemy jeszcze funkcje straty zgodne z warunkami Dirichleta i von Neumanna: $e_{2,i}(\cdot) = 0.5e_{1,i}(0)$, $e_{3,i}(\cdot) = 0.5e_{1,i}(0.5)$.

4.2 Pochodne funkcji straty

Odpowiednie pochodne funkcji straty zostały policzone symbolicznie w kodzie Matlaba, który zamieścimy w niniejszej sekcji w dalszym ciągu raportu.

4.3 Pseudokod procesu uczenia

1. Dane wejściowe - liczba warstw.
2. Generujemy dataset składający się z generacji $x \in (0, 0.5)$.
3. Korzystając ze znanego rozwiązania problemu IGA, generujemy współczynniki u_1, u_2, u_3 .
4. Dla każdej warstwy sieci oraz dla każdego współczynnika u_i :
 - (a) Liczymy $PINN(x)$.
 - (b) Liczymy $e_1(x)$, $e_2(\cdot)$ oraz $e_3(\cdot)$
 - (c) Liczymy pochodne cząstkowe pierwszego rzędu z wyżej zdefiniowanych błędów po każdym parametrze.
 - (d) Uczymy parametry stochastycznym spadkiem wzdłuż gradientu, biorąc stałą uczącą $\eta \in (0, 1)$.

Kod Matlaba

```
1 function ANN_3(layers_number)
2 %
   %%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%
```

```

3 % Creation of dataset
4 % Here we solve the projection of the known solution u
    =sin(n*pi*x)
5 A = [1/5 1/10 1/30; 1/10 2/15 1/10; 1/30 1/10 1/5];
6 i=1;
7 for n=0.01:0.01:0.5
8 rhs= [ (pi*pi*n*n+2*cos(pi*n)-2)/(pi*pi*pi*n*n*n);
9 (-2*pi*n*sin(pi*n)-4*cos(pi*n)+4)/(pi*pi*pi*n*n*n);
10 ((2-pi*pi*n*n)*cos(pi*n)+2*pi*n*sin(pi*n)-2)/(pi*pi*pi
    *n*n*n) ];
11 u=A \ rhs;
12 dataset_in(i)=n;
13 dataset_u1(i)=u(1);
14 dataset_u2(i)=u(2);
15 dataset_u3(i)=u(3);
16 i=i+1;
17 end
18 ndataset=i-1;
19 %
    %%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%

20 % Training
21 %Initialization for every (three in this case)
    coefficients of a linear
22 %combination of B-spline functions
23 vec_a1=ones(1, layers_number);
24 vec_b1=ones(1, layers_number);
25 vec_c1=ones(1, layers_number);
26 vec_d1=zeros(1, layers_number);
27
28 vec_a2=ones(1, layers_number);
29 vec_b2=ones(1, layers_number);
30 vec_c2=ones(1, layers_number);

```

```

31 vec_d2=zeros(1, layers_number);
32
33 vec_a3=ones(1, layers_number);
34 vec_b3=ones(1, layers_number);
35 vec_c3=ones(1, layers_number);
36 vec_d3=zeros(1, layers_number);
37
38 smallest_err_u1=1000;
39 smallest_err_u2=1000;
40 smallest_err_u3=1000;
41
42 biggest_err_u1=0;
43 biggest_err_u2=0;
44 biggest_err_u3=0;
45
46 eta1=0.1;
47 eta2=0.1;
48 eta3=0.1;
49 r = 0 + (1-0).*rand(ndataset,1);
50 r=r.*ndataset;
51 n=0.444;
52 for idx=1:layers_number
53     %Symbolic functions
54
55     %Symbolic sigmoid
56     syms z a1 b1
57     a=sym('a', [1, idx]);
58     b=sym('b', [1, idx]);
59     c=sym('c', [1, idx]);
60     d=sym('d', [1, idx]);
61
62     sigmoid(z,a1,b1) = a1/(1+exp(-z))+b1;
63

```

```

64     result=sigmoid(z*a(idx)+b(idx), c(idx), d(idx));
65     if(idx>1)
66         for l=1:idx-1
67             result=sigmoid(a(idx-l)*result+b(idx-l), c
                (idx-l), d(idx-l));
68         end
69     end
70     ann_3(z,a,b,c,d)=result;
71
72
73     %Symbolic first and second derivative of PINN with
        respect to x
74     ann_3_x(z,a,b,c,d)=diff(ann_3, z);
75     ann_3_xx(z,a,b,c,d)=diff(ann_3_x, z);
76
77     %Symbolic PDE solver function
78     temp=[a, b, c, d];
79     combined=temp(:);
80     combined=num2cell(combined);
81     F(z,a, b, c, d)=ann_3_xx(z, combined{:}) + n^2*pi
        ^2*sin(n*pi*z);
82
83     %Symbolic error1 function
84     error1(z, a, b, c, d)=0.5*F(z, combined{:})^2;
85
86     %Symbolic error2 function
87     error2(a, b, c, d)=0.5*ann_3(0, combined{:});
88
89     %Symbolic error3 function
90     error3(a, b, c, d)=0.5*(ann_3_x(0.5, combined{:})
        - n*pi*cos(n*pi*0.5))^2;
91
92     for j=1:ndataset

```

```

93     params_u1(1:idx)=vec_a1(1:idx);
94     params_u1(idx+1:2*idx)=vec_b1(1:idx);
95     params_u1(2*idx+1:3*idx)=vec_c1(1:idx);
96     params_u1(3*idx+1:4*idx)=vec_d1(1:idx);
97
98     params_u2(1:idx)=vec_a2(1:idx);
99     params_u2(idx+1:2*idx)=vec_b2(1:idx);
100    params_u2(2*idx+1:3*idx)=vec_c2(1:idx);
101    params_u2(3*idx+1:4*idx)=vec_d2(1:idx);
102
103    params_u3(1:idx)=vec_a3(1:idx);
104    params_u3(idx+1:2*idx)=vec_b3(1:idx);
105    params_u3(2*idx+1:3*idx)=vec_c3(1:idx);
106    params_u3(3*idx+1:4*idx)=vec_d3(1:idx);
107
108    params_u1_combined=num2cell(params_u1);
109    params_u2_combined=num2cell(params_u2);
110    params_u3_combined=num2cell(params_u3);
111
112    i=floor(r(j));
113    if(i==0)
114        i=1;
115    end
116
117    %Approximation of u1, u2 and u3 coefficients
118    eval_u1 = double(ann_3(dataset_in(i),
119        params_u1_combined{:}));
120    eval_u2 = double(ann_3(dataset_in(i),
121        params_u2_combined{:}));
122    eval_u3 = double(ann_3(dataset_in(i),
123        params_u3_combined{:}));
124
125    %Errors

```

```

123     error_u1 = 0.5*(eval_u1-dataset_u1(i))^2;
124     error_u2 = 0.5*(eval_u2-dataset_u2(i))^2;
125     error_u3 = 0.5*(eval_u3-dataset_u3(i))^2;
126
127     %Symbolic differentiation
128     d_error_1_a(z, a, b, c, d)=diff(error1, a(idx)
        );
129     d_error_1_b(z,a, b, c, d)=diff(error1, b(idx))
        ;
130     d_error_1_c(z, a, b, c, d)=diff(error1, c(idx)
        );
131     d_error_1_d(z, a, b, c, d)=diff(error1, d(idx)
        );
132
133     derror_u1_1a=double(d_error_1_a(dataset_in(i),
        params_u1_combined{:}));
134     derror_u1_1b=double(d_error_1_b(dataset_in(i),
        params_u1_combined{:}));
135     derror_u1_1c=double(d_error_1_c(dataset_in(i),
        params_u1_combined{:}));
136     derror_u1_1d=double(d_error_1_d(dataset_in(i),
        params_u1_combined{:}));
137
138     derror_u2_1a=double(d_error_1_a(dataset_in(i),
        params_u2_combined{:}));
139     derror_u2_1b=double(d_error_1_b(dataset_in(i),
        params_u2_combined{:}));
140     derror_u2_1c=double(d_error_1_c(dataset_in(i),
        params_u2_combined{:}));
141     derror_u2_1d=double(d_error_1_d(dataset_in(i),
        params_u2_combined{:}));
142
143     derror_u3_1a=double(d_error_1_a(dataset_in(i),

```

```

        params_u3_combined{:}));
144     derror_u3_1b=double(d_error_1_b(dataset_in(i),
        params_u3_combined{:}));
145     derror_u3_1c=double(d_error_1_c(dataset_in(i),
        params_u3_combined{:}));
146     derror_u3_1d=double(d_error_1_d(dataset_in(i),
        params_u3_combined{:}));
147
148     % Training of the boundary condition at x=0
149     d_error_2_a(a, b, c, d)=diff(error2, a(idx));
150     d_error_2_b(a, b, c, d)=diff(error2, b(idx));
151     d_error_2_c(a, b, c, d)=diff(error2, c(idx));
152     d_error_2_d(a, b, c, d)=diff(error2, d(idx));
153
154     derror_u1_2a=double(d_error_2_a(
        params_u1_combined{:}));
155     derror_u1_2b=double(d_error_2_b(
        params_u1_combined{:}));
156     derror_u1_2c=double(d_error_2_c(
        params_u1_combined{:}));
157     derror_u1_2d=double(d_error_2_d(
        params_u1_combined{:}));
158
159     derror_u2_2a=double(d_error_2_a(
        params_u2_combined{:}));
160     derror_u2_2b=double(d_error_2_b(
        params_u2_combined{:}));
161     derror_u2_2c=double(d_error_2_c(
        params_u2_combined{:}));
162     derror_u2_2d=double(d_error_2_d(
        params_u2_combined{:}));
163
164     derror_u3_2a=double(d_error_2_a(

```



```

        params_u3_combined{:}));
165 derror_u3_2b=double(d_error_2_b(
        params_u3_combined{:}));
166 derror_u3_2c=double(d_error_2_c(
        params_u3_combined{:}));
167 derror_u3_2d=double(d_error_2_d(
        params_u3_combined{:}));
168
169
170 % Training of the boundary condition at x=0.5
171 d_error_3_a(a,b, c, d)=diff(error3, a(idx));
172 d_error_3_b(a, b, c, d)=diff(error3, b(idx));
173 d_error_3_c(a,b, c, d)=diff(error3, c(idx));
174 d_error_3_d(a, b, c, d)=diff(error3, d(idx));
175
176 derror_u1_3a=double(d_error_3_a(
        params_u1_combined{:}));
177 derror_u1_3b=double(d_error_3_b(
        params_u1_combined{:}));
178 derror_u1_3c=double(d_error_3_c(
        params_u1_combined{:}));
179 derror_u1_3d=double(d_error_3_d((
        params_u1_combined{:})));
180
181 derror_u2_3a=double(d_error_3_a(
        params_u2_combined{:}));
182 derror_u2_3b=double(d_error_3_b(
        params_u2_combined{:}));
183 derror_u2_3c=double(d_error_3_c(
        params_u2_combined{:}));
184 derror_u2_3d=double(d_error_3_d(
        params_u2_combined{:}));
185

```

```

186     derror_u3_3a=double(d_error_3_a(
        params_u3_combined{:}));
187     derror_u3_3b=double(d_error_3_b(
        params_u3_combined{:}));
188     derror_u3_3c=double(d_error_3_c(
        params_u3_combined{:}));
189     derror_u3_3d=double(d_error_3_d(
        params_u3_combined{:}));

190
191     vec_a1(idx)=vec_a1(idx) - eta1*(derror_u1_3a+
        derror_u1_2a+derror_u1_1a);
192     vec_b1(idx)=vec_b1(idx) - eta1*(derror_u1_3b+
        derror_u1_2b+derror_u1_1b);
193     vec_c1(idx)=vec_c1(idx) - eta1*(derror_u1_3c+
        derror_u1_2c+derror_u1_1c);
194     vec_d1(idx)=vec_d1(idx) - eta1*(derror_u1_3d+
        derror_u1_2d+derror_u1_1d);

195
196     vec_a2(idx)=vec_a2(idx) - eta2*(derror_u2_3a+
        derror_u2_2a+derror_u2_1a);
197     vec_b2(idx)=vec_b2(idx) - eta2*(derror_u2_3b+
        derror_u2_2b+derror_u2_1b);
198     vec_c2(idx)=vec_c2(idx) - eta2*(derror_u2_3c+
        derror_u2_2c+derror_u2_1c);
199     vec_d2(idx)=vec_d2(idx) - eta2*(derror_u2_3d+
        derror_u2_2d+derror_u2_1d);

200
201     vec_a3(idx)=vec_a3(idx) - eta3*(derror_u3_3a+
        derror_u3_2a+derror_u3_1a);
202     vec_b3(idx)=vec_b3(idx) - eta3*(derror_u3_3b+
        derror_u3_2b+derror_u3_1b);
203     vec_c3(idx)=vec_c3(idx) - eta3*(derror_u3_3c+
        derror_u3_2c+derror_u3_1c);

```

```

204         vec_d3(idx)=vec_d3(idx) - eta3*(derror_u3_3d+
                derror_u3_2d+derror_u3_1d);

205
206         if(error_u1 < smallest_err_u1)
207             smallest_err_u1=error_u1;
208             best_params_u1=num2cell(params_u1);
209             min_diff_u1=error_u1;
210         end
211
212         if(error_u1 > biggest_err_u1)
213             biggest_err_u1=error_u1;
214             max_diff_u1=error_u1;
215         end
216
217         if(error_u2 < smallest_err_u2)
218             smallest_err_u2=error_u2;
219             best_params_u2=num2cell(params_u2);
220             min_diff_u2=error_u2;
221         end
222
223         if(error_u2 > biggest_err_u2)
224             biggest_err_u2=error_u2;
225             max_diff_u2=error_u2;
226         end
227
228         if(error_u3 < smallest_err_u3)
229             smallest_err_u3=error_u3;
230             best_params_u3=num2cell(params_u3);
231             min_diff_u3=error_u3;
232         end
233
234         if(error_u3 > biggest_err_u3)
235             biggest_err_u3=error_u3;

```

```

236         max_diff_u3=error_u3;
237     end
238
239     yeval_u1(j+(idx*ndataset-ndataset))=eval_u1;
240     yeval_u2(j+(idx*ndataset-ndataset))=eval_u2;
241     yeval_u3(j+(idx*ndataset-ndataset))=eval_u3;
242
243     ya_u1(j+(idx*ndataset-ndataset))=vec_a1(idx);
244     yb_u1(j+(idx*ndataset-ndataset))=vec_b1(idx);
245     yc_u1(j+(idx*ndataset-ndataset))=vec_c1(idx);
246     yd_u1(j+(idx*ndataset-ndataset))=vec_d1(idx);
247
248     ya_u2(j+(idx*ndataset-ndataset))=vec_a2(idx);
249     yb_u2(j+(idx*ndataset-ndataset))=vec_b2(idx);
250     yc_u2(j+(idx*ndataset-ndataset))=vec_c2(idx);
251     yd_u2(j+(idx*ndataset-ndataset))=vec_d2(idx);
252
253     ya_u3(j+(idx*ndataset-ndataset))=vec_a3(idx);
254     yb_u3(j+(idx*ndataset-ndataset))=vec_b3(idx);
255     yc_u3(j+(idx*ndataset-ndataset))=vec_c3(idx);
256     yd_u3(j+(idx*ndataset-ndataset))=vec_d3(idx);
257
258
259     yy_u1(j+(idx*ndataset-ndataset))=dataset_u1(i)
260         ;
261     yy_u2(j+(idx*ndataset-ndataset))=dataset_u2(i)
262         ;
263     yy_u3(j+(idx*ndataset-ndataset))=dataset_u3(i)
264         ;
265     ye_u1(j+(idx*ndataset-ndataset))=error_u1
266     ye_u2(j+(idx*ndataset-ndataset))=error_u2;
267     ye_u3(j+(idx*ndataset-ndataset))=error_u3;
268     j

```

```

266         end
267         idx
268     end
269
270     %
271     %%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%
272
271 % plot convergence
272 x=1:layers_number*ndataset;
273 % hold on
274 % Vectors parameters have parameters from every layer
275 % on the same plot!
275 plot(x,ya_u1,x,yb_u1,x,yc_u1,x,yd_u1);
276 h=legend('a_{u1}', 'b_{u1}', 'c_{u1}', 'd_{u1}');
277 set(h,'FontSize',10);
278 figure
279
280 plot(x,ya_u2,x,yb_u2,x,yc_u2,x,yd_u2);
281 h=legend('a_{u2}', 'b_{u2}', 'c_{u2}', 'd_{u2}');
282 set(h,'FontSize',10);
283 figure
284
285 plot(x,ya_u3,x,yb_u3,x,yc_u3,x,yd_u3);
286 h=legend('a_{u3}', 'b_{u3}', 'c_{u3}', 'd_{u3}');
287 set(h,'FontSize',10);
288
289 figure
290
291 %
292 %%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%
293
292 % plot error
293 x=1:1:layers_number*ndataset;

```


```

294 % hold on
295
296 plot(x, ye_u1, x, ye_u2, x, ye_u3);
297 h=legend('error(u1)', 'error(u2)', 'error(u3)');
298 set(h, 'FontSize', 20);
299 set(gca, 'YScale', 'log');
300
301 %
302 %%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%
303 % Computing maximum and minimum difference for u(1), u
304 % (2) and u(3)
305
306 max_diff_u1
307 min_diff_u1
308
309 max_diff_u2
310 min_diff_u2
311
312 max_diff_u3
313 min_diff_u3
314
315 %
316 %%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%
317
318 best_params_u1
319 best_params_u2
320 best_params_u3
321 end

```

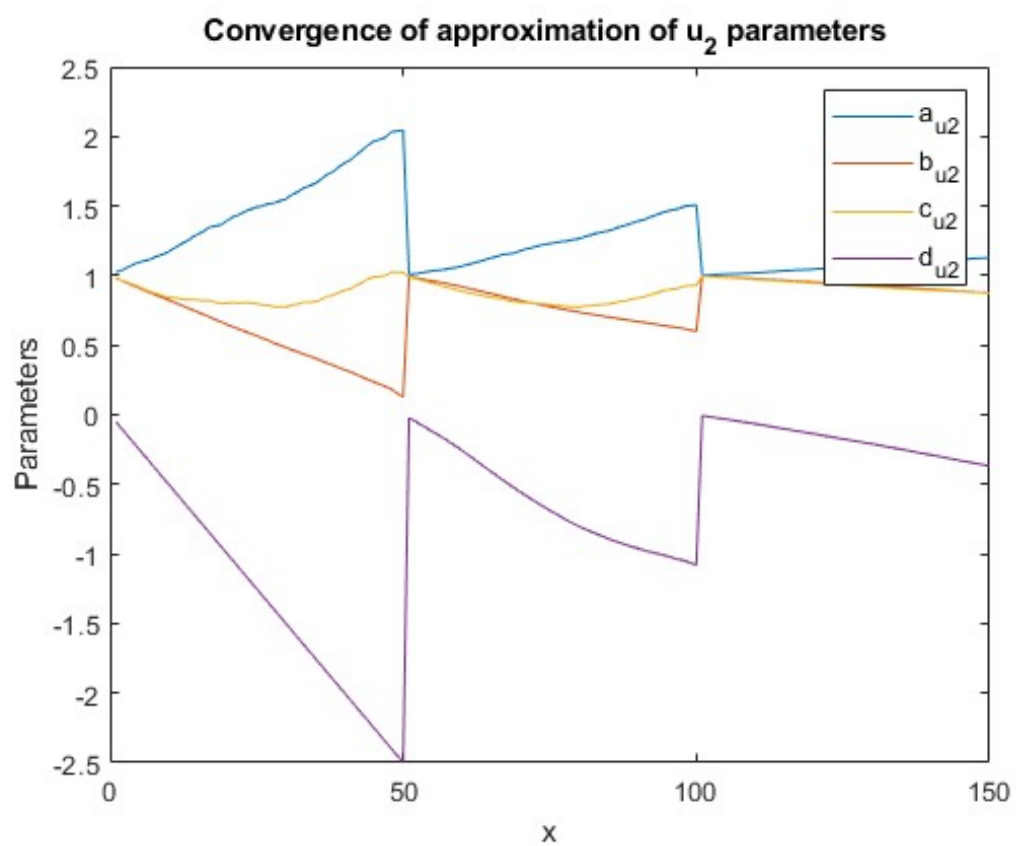
4.4 Zbieżność współczynników

- Dla u_1




Rysunek 7: Zbieżność uczonych parametrów u_1

- Dla u_2




Rysunek 8: Zbieżność uczonych parametrów u_2

- Dla u_3



Rysunek 9: Zbieżność uczonych parametrów u_3

4.5 Zbieżność błędu funkcji straty



Rysunek 10: Zbieżność błędu

4.6 Maksymalna, minimalna wartość błędu

- Dla u_1
 - Największy błąd: 2.3717
 - Najmniejszy błąd: $4.2174e^{-4}$
- Dla u_2
 - Największy błąd: 4.5774
 - Najmniejszy błąd: $4.5347e^{-4}$
- Dla u_3

- Największy błąd: 4.9766
- Najmniejszy błąd: 0.0020